

Propuestas de proyectos de HPC

Aplicaciones en: computación cuántica en materiales, incendios forestales
y gemelos digitales

José Sebastian Sasías, MSc. Ing.

Resumen

Se presentan tres propuestas de proyectos de computación de alto desempeño (HPC). La primera combina computación cuántica híbrida y modelado QUBO para optimizar la composición y proceso de nuevos materiales compuestos. La segunda integra inteligencia artificial con el modelo físico de Rothermel para predecir la propagación de incendios forestales en tiempo acelerado. La tercera emplea HPC e IA aceleradora (predictor GNN, VAE generativo, RL) para descubrir automáticamente ecuaciones diferenciales a partir de datos de entrada/salida, generando gemelos digitales interpretables.

Para cada propuesta se resumen problema, justificación de HPC, estrategia de resolución y evaluación experimental. Posteriormente se desarrollan en detalle, analizando impacto, innovación y conveniencia para un estudiante de doctorado.

Índice

1. Resumen ejecutivo de las tres propuestas	3
1.1. Propuesta 1: Optimización híbrida cuántico-clásica de composites estructurales	3
1.2. Propuesta 2: Predicción de incendios forestales con IA + modelo de Rothermel	3
1.3. Propuesta 3: Descubrimiento de ecuaciones para gemelos digitales mediante IA aceleradora en HPC	3
2. Desarrollo detallado de las propuestas	4
2.1. Propuesta 1: Optimización híbrida cuántico-clásica de composites estructurales	4
2.1.1. Descripción del problema	4
2.1.2. Justificación de HPC	4
2.1.3. Estrategia de resolución	4
2.1.4. Evaluación experimental	5
2.1.5. Impacto e innovación	5
2.2. Propuesta 2: Predicción de incendios forestales con IA + modelo de Rothermel	5
2.2.1. Descripción del problema	5
2.2.2. Justificación de HPC	6
2.2.3. Estrategia de resolución	6
2.2.4. Evaluación experimental	6
2.2.5. Impacto e innovación	7

2.3. Propuesta 3: Descubrimiento de ecuaciones para gemelos digitales mediante IA aceleradora en HPC	7
2.3.1. Descripción del problema	7
2.3.2. Justificación de HPC e IA aceleradora	7
2.3.3. Estrategia de resolución	7
2.3.4. Evaluación experimental	8
2.3.5. Impacto e innovación	8
3. Comparativa y recomendación para doctorado	9
3.1. Criterios de comparación	9
3.2. Análisis	9
3.3. Recomendación	9
3.4. Plan de contingencia	10
4. Conclusiones	10
Anexo: Glosario de términos y definiciones	11
Anexo: Sustento de la novedad de la Propuesta 3	12

1. Resumen ejecutivo de las tres propuestas

1.1. Propuesta 1: Optimización híbrida cuántico-clásica de composites estructurales

Descripción	Optimización simultánea de proporciones de fases (fibras, matriz, aditivos) y parámetros de proceso (curado, moldeado, compresión) para maximizar prestaciones mecánicas y minimizar peso. Modelado como QUBO.
Justificación HPC	Espacio de búsqueda masivo ($> 10^6$ combinaciones); cada evaluación requiere simulación FEM costosa (2-5 min); el solver cuántico (QPU) debe ser alimentado con cientos de miles de QUBOs.
Estrategia	Islas evolutivas clásicas + envío periódico de QUBOs a la QPU. Balance mediante work stealing; checkpoints para tolerancia a fallos.
Evaluación	Speedup vs. SA clásico, escalabilidad fuerte/débil, tiempo-to-solution, energía de solución QUBO.

1.2. Propuesta 2: Predicción de incendios forestales con IA + modelo de Rothermel

Descripción	Simulación en tiempo acelerado de propagación de incendios usando el modelo físico de Rothermel, cuyos parámetros se calibran dinámicamente con una red neuronal (entrenada offline en HPC).
Justificación HPC	Dominio 2D de hasta 1000x1000 celdas; múltiples escenarios Monte Carlo; la inferencia de la IA debe ser paralela y solaparse con el cómputo físico.
Estrategia	Descomposición espacial con halos, balance dinámico por carga de trabajo, GPU para inferencia, checkpoints cada minuto.
Evaluación	Speedup frente a CPU secuencial, escalabilidad débil, precisión en holdout temporal, robustez ante ruido meteorológico.

1.3. Propuesta 3: Descubrimiento de ecuaciones para gemelos digitales mediante IA aceleradora en HPC

Descripción	A partir solo de señales de entrada $u(t)$ y salida $y(t)$ de un dispositivo real, descubrir automáticamente la EDO/EDP subyacente (ej. $dy/dt = f(y, u)$) usando regresión simbólica paralela.
Justificación HPC	Espacio de expresiones astronómico; cada candidato requiere integración numérica costosa; se entrena un predictor neuronal (surrogate) que filtra el 90 % de las expresiones sin integrar.
Estrategia	GP por islas + predictor GNN + VAE generativo + RL adaptativo. Balance con batch evaluation en GPU y work stealing. Tolerancia mediante checkpoints y replicación de modelos IA.
Evaluación	Speedup frente a GP puro, precisión del predictor, estabilidad bootstrap, capacidad de extrapolación, lazo cerrado.

2. Desarrollo detallado de las propuestas

2.1. Propuesta 1: Optimización híbrida cuántico-clásica de composites estructurales

2.1.1. Descripción del problema

Se desea diseñar un material compuesto de matriz polimérica reforzada con fibras de carbono y aditivos cerámicos. Las variables de decisión incluyen:

- Proporciones volumétricas de cada fase (discretizadas en niveles).
- Parámetros de proceso: temperatura de curado, presión de moldeo, velocidad de compresión, tiempo de fraguado.

El objetivo es maximizar la resistencia a tracción y minimizar la masa, sujeto a restricciones de procesabilidad (por ejemplo, evitar curados incompletos o tensiones residuales). El problema se formula como una optimización combinatoria con función objetivo no lineal evaluada mediante simulaciones de elementos finitos (FEM). Se modela como un problema QUBO (Quadratic Unconstrained Binary Optimization) donde las variables binarias codifican las proporciones y parámetros, y las penalizaciones cuadráticas imponen restricciones de proceso.

2.1.2. Justificación de HPC

- El espacio de búsqueda crece exponencialmente: típicamente 10^6 a 10^9 combinaciones.
- Cada simulación FEM dura entre 2 y 5 minutos en un núcleo CPU.
- El solver cuántico (ej. D-Wave Advantage) requiere que cada QUBO sea enviado y procesado; la sobrecarga de comunicación es significativa.
- La hibridación cuántico-clásica necesita ejecutar simultáneamente muchos QUBOs en clásico mientras la QPU resuelve otros.

2.1.3. Estrategia de resolución

- **Modelado QUBO:** Se discretizan proporciones y parámetros. Las restricciones (ej. suma de proporciones = 1) se introducen como penalizaciones $P(\sum x_i - 1)^2$. Los parámetros de proceso se codifican en binario one-hot.
- **Hibridación paralela:**
 - Un *master* genera lotes de QUBOs (variantes con pesos perturbados).
 - Los *workers* clásicos (CPUs) ejecutan solvers de recocido simulado paralelo (SA) o búsqueda tabú.
 - Periódicamente, se envían los QUBOs más prometedores a la QPU (D-Wave) mediante su API.
 - Las soluciones de la QPU se usan para sembrar la siguiente generación de QUBOs.

- **Balance de carga:** Cola dinámica de tareas (QUBOs a resolver). Workers rápidos toman más tareas. Work stealing entre workers.
- **Tolerancia a fallos:** Checkpoints cada 10 minutos almacenando la mejor solución y el estado de la cola. Si un worker cae, sus tareas se reasignan. Reintentos automáticos en envíos a QPU (hasta 3 veces).

2.1.4. Evaluación experimental

- **Speedup:** Comparar tiempo para alcanzar una solución de calidad conocida (ej. 99 % del óptimo) usando: (a) SA secuencial en 1 CPU, (b) SA paralelo en 128 CPUs, (c) híbrido (128 CPUs + QPU). Se espera speedup $> 20\times$ frente a SA secuencial.
- **Escalabilidad fuerte:** Fijar tamaño del problema (8 materiales, 64 niveles de proceso) y aumentar CPUs de 1 a 256. Medir eficiencia $= T_1/(N \cdot T_N)$.
- **Escalabilidad débil:** Duplicar variables QUBO y nodos, observar tiempo por generación.
- **Métrica cuántica:** Tiempo-to-solution (TTS) y energía de la solución en función del número de llamadas a la QPU.

2.1.5. Impacto e innovación

- **Impacto académico:** Publicación en revistas de materiales computacionales (*Computational Materials Science*) y en conferencias de computación cuántica (QCE, TQC).
- **Impacto industrial:** Método transferible a cualquier problema de optimización de procesos (polímeros, cerámicas, aleaciones). Empresas de materiales avanzados (Toray, Hexcel) son potenciales interesadas.
- **Nivel de innovación:** Alto – la hibridación QUBO+FEM+HPC para procesos de manufactura es novedosa. El ajuste de penalizaciones para restricciones de moldeado/curado no ha sido explorado.

2.2. Propuesta 2: Predicción de incendios forestales con IA + modelo de Rothermel

2.2.1. Descripción del problema

El modelo de Rothermel predice la velocidad de propagación del frente de un incendio en función de:

- Combustible (carga, humedad, relación superficie-volumen).
- Topografía (pendiente, orientación).
- Meteorología (velocidad y dirección del viento).

Sin embargo, sus parámetros empíricos se calibran para condiciones medias y fallan en situaciones extremas o con combustibles heterogéneos. La propuesta es entrenar una red neuronal (CNN recurrente) que, observando el estado local del incendio y las condiciones

ambientales, ajuste en tiempo real los parámetros de Rothermel para cada celda. El resultado es un modelo híbrido (física + IA) ejecutado en HPC para predicciones a 6 horas con actualizaciones cada 5 minutos.

2.2.2. Justificación de HPC

- Dominios grandes (hasta 2000×2000 celdas) y mallas adaptativas.
- El modelo de Rothermel se evalúa para cada celda en cada paso temporal, con dependencias espaciales (frente de fuego).
- La red neuronal debe inferir parámetros para miles de celdas simultáneamente.
- Se requieren ejecuciones Monte Carlo para incertidumbre meteorológica.

2.2.3. Estrategia de resolución

- **Descomposición espacial:** El dominio se divide en bloques mediante particionamiento regular (MPI). Cada bloque tiene capas fantasma (halos) de 2-3 celdas para propagación.
- **Modelo híbrido:**
 - Cada bloque ejecuta el núcleo de Rothermel en CPU (optimizado con vectorización AVX).
 - Cada 5 pasos temporales, se lanza la red neuronal (MLP de 4 capas) en GPU para predecir correcciones locales a los parámetros de Rothermel.
- **Balance de carga:** Se monitoriza el tiempo de cómputo por bloque. Bloques con topografía compleja (más celdas activas) reciben más workers. Se usa *redistribución dinámica* cada 100 pasos.
- **Tolerancia a fallos:** Checkpoints completos del estado del fuego cada minuto. Si un nodo falla, su bloque se reasigna y se reinicia desde el último checkpoint. Las inferencias de IA se guardan en caché.

2.2.4. Evaluación experimental

- **Speedup:** Comparar una simulación de 6 horas (tiempo físico) con: (a) CPU secuencial, (b) 128 CPUs, (c) 128 CPUs + 4 GPUs. Objetivo: lograr tiempo de cómputo menor al tiempo real (es decir, 6 horas de fuego simuladas en menos de 6 horas).
- **Escalabilidad débil:** Duplicar área ($1000^2 \rightarrow 2000^2 \rightarrow 4000^2$) y nodos ($4 \rightarrow 16 \rightarrow 64$). Medir tiempo de simulación por paso.
- **Precisión:** Usar datos históricos de incendios reales (ej. California Fire Perimeter Data) para validar la posición del frente cada hora. Métrica: MAE en metros.
- **Robustez:** Añadir ruido a los datos de viento (derivados de modelos meteorológicos) y medir degradación.

2.2.5. Impacto e innovación

- **Impacto académico:** Revistas de simulación ambiental (*Environmental Modelling & Software*) o de computación de alto rendimiento (*IJHPCA*). Conferencias: SC, PASC, IEEE eScience.
- **Impacto industrial:** Protección civil, bomberos, compañías forestales. Potencial transferencia a sistemas de alerta temprana (ej. European Forest Fire Information System).
- **Nivel de innovación:** Medio-Alto. La combinación de Rothermel con IA ajustable en tiempo real es novedosa. El paralelismo adaptativo para incendios en topografía compleja también lo es.

2.3. Propuesta 3: Descubrimiento de ecuaciones para gemelos digitales mediante IA aceleradora en HPC

2.3.1. Descripción del problema

Dado únicamente un conjunto de datos de entrada $u(t)$ y salida $y(t)$ provenientes de un dispositivo físico real (sin conocimiento previo del modelo), se desea encontrar automáticamente una ecuación diferencial ordinaria (EDO) o en derivadas parciales (EDP) que describa la dinámica:

$$\frac{dy}{dt} = f(y, u, t) \quad \text{o} \quad y(t) = \mathcal{F}[u(\tau), \tau \leq t]$$

La expresión debe ser interpretable (símbolos matemáticos) y servir como núcleo de un gemelo digital para simulación, control y diagnóstico.

2.3.2. Justificación de HPC e IA aceleradora

- El espacio de expresiones posibles es astronómico ($> 10^{15}$ árboles de hasta profundidad 10).
- Cada expresión candidata requiere integrar numéricamente la EDO (entre 10^4 y 10^6 puntos), con costo de 0.01 a 1 segundo.
- Un predictor neuronal (surrogate) entrenado sobre evaluaciones reales puede estimar el error sin integrar, filtrando el 85-90 % de los candidatos.
- El entrenamiento del predictor, del VAE generativo y del agente RL se hace online en paralelo.

2.3.3. Estrategia de resolución

- **Arquitectura general:**
 - *Fase inicial:* Se evalúa un conjunto de 10^6 expresiones aleatorias (paralelizadas en GPU). Con esos datos se entrena un predictor GNN (Graph Neural Network) que mapea el árbol sintáctico a un error esperado.

- *Búsqueda evolutiva paralela*: Se ejecutan 32 a 128 islas de programación genética. Antes de integrar una expresión, se consulta al predictor; solo el top 10 % se integra realmente.
 - *Generación VAE*: Un VAE entrenado con todas las expresiones evaluadas produce nuevos individuos en el espacio latente, reemplazando mutaciones aleatorias.
 - *RL adaptativo*: Un agente PPO por isla ajusta la tasa de mutación, probabilidad de cruce y otros hiperparámetros.
- **Balance de carga**:
 - Cada isla gestiona su población en un nodo HPC. Dentro del nodo, un pool de hilos (CPUs) lanza lotes de expresiones a las GPUs para integración.
 - El predictor GNN se ejecuta en GPU con batch size 4096, solapado con la integración.
 - **Tolerancia a fallos**: Checkpoints de población y de los modelos IA cada 15 minutos. Los modelos IA se replican en tres nodos. Si una GPU falla, la integración se reasigna a CPU (más lento pero no se pierde el progreso).

2.3.4. Evaluación experimental

- **Speedup**:
 - GP clásico (sin IA) en 64 nodos vs. GP+IA en 64 nodos.
 - También comparar contra 1 CPU secuencial.
- **Precisión del predictor**: Correlación de Pearson entre error predicho y error real en conjunto de test.
- **Escalabilidad débil**: Duplicar población total y nodos, medir tiempo por generación.
- **Confiabilidad del modelo descubierto**:
 - Holdout temporal (70/15/15).
 - Bootstrap de 100 réplicas para medir estabilidad estructural.
 - Prueba de extrapolación fuera del rango de entrenamiento.
 - Simulación en lazo cerrado.

2.3.5. Impacto e innovación

- **Impacto académico**: Altísimo. Fusión de HPC, regresión simbólica, GNNs, VAE y RL. Publicaciones en revistas como *Journal of Computational Physics*, *Machine Learning: Science and Technology*, o *IEEE TPAMI*. Conferencias: NeurIPS (simbolismo neuronal), SC, PASC.
- **Impacto industrial**: Cualquier industria con dispositivos físicos (automoción, energía, aeroespacial, química) puede generar gemelos digitales interpretables sin necesidad de conocimiento experto. Empresas como Siemens, ABB, GE, Bosch son potenciales colaboradoras.

- **Nivel de innovación:** Muy alto. La combinación de predictor GNN + VAE generativo + RL adaptativo para regresión simbólica en HPC no se ha encontrado en publicaciones hasta la fecha. Es una frontera del aprendizaje simbólico.

3. Comparativa y recomendación para doctorado

3.1. Criterios de comparación

Se evalúan las tres propuestas según los siguientes criterios (escala 1 a 5, siendo 5 el mejor):

Criterio	P.1(Cuántica)	P.2(Incendios)	P.3(Gemelo Dig)
Impacto académico	4	3	5
Impacto industrial	4	4	5
Novedad / innovación	4	3	5
Complejidad técnica	4 (requiere QPU)	3	5
Riesgo de no lograr resultados	3 (disponib QPU)	2 (datos difíciles)	3 (convergencia RL)
Visibilidad en conferencias top	4 (QCE, SC)	3 (SC, IEEE eScience)	5 (NeurIPS, SC, PASC)
Prob de publicar artículos	Alta	Media	Muy alta
Aprendizaje para doctorando	Cuántica, optimización, HPC	Modelado físico, HPC, IA	IA avanzada, HPC, sistemas complejos

3.2. Análisis

- **Propuesta 1 (Cuántica):** Excelente si el doctorando tiene interés en computación cuántica y acceso garantizado a una QPU (D-Wave o similar). El riesgo principal es la disponibilidad de tiempo de máquina cuántica. El impacto académico es notable, pero el campo está muy competido.
- **Propuesta 2 (Incendios):** La más aplicada y con posible colaboración con bomberos/protección civil. Menor novedad científica pero mayor probabilidad de éxito rápido. Ideal para un doctorando que prefiera un problema bien acotado con datos reales accesibles.
- **Propuesta 3 (Gemelo Digital):** La más innovadora y con mayor potencial de publicaciones de alto impacto. Integra técnicas de vanguardia (GNN simbólico, VAE, RL, GP paralelo). Sin embargo, es la más compleja y con riesgo de no convergencia si no se afinan bien los hiperparámetros. Es la que mejor prepara al estudiante para I+D en industria (gemelos digitales, IA explicable, HPC).

3.3. Recomendación

Se recomienda la **Propuesta 3 (Descubrimiento de ecuaciones para gemelos digitales con IA aceleradora en HPC)** por las siguientes razones:

1. **Máxima valoración en entornos académicos y laborales:** Los gemelos digitales y la IA simbólica son temas prioritarios en la agenda europea (Horizon Europe) y nacional (IAE, CDTI). Un doctorado en esta línea permite transitar tanto a grupos de investigación de élite como a departamentos de I+D de grandes empresas (Siemens, Bosch, Airbus).

2. **Alto factor de innovación:** La combinación de GNN predictor + VAE generativo + RL nunca se ha aplicado a regresión simbólica en HPC. Es prácticamente garantía de publicaciones en conferencias A (NeurIPS, ICML, SC) y revistas JCR Q1.
3. **Transferibilidad:** Los métodos desarrollados son agnósticos al dominio, lo que facilita colaboraciones con múltiples industrias.
4. **Formación integral:** El doctorando aprenderá: HPC (MPI, CUDA, balanceo de carga), aprendizaje profundo (GNN, VAE, RL), modelado matemático (EDOs, integración numérica) y optimización evolutiva. Perfil altamente demandado.

3.4. Plan de contingencia

Dada la complejidad, se recomienda un enfoque incremental:

1. Implementar primero regresión simbólica paralela sin IA (GP clásico) para tener una línea base.
2. Añadir predictor GNN y medir speedup.
3. Incorporar VAE para generación.
4. Finalmente integrar RL adaptativo.

Si alguna componente no funciona, las anteriores ya proporcionan contribuciones publicables.

4. Conclusiones

Se han presentado tres propuestas de proyectos HPC con diferentes grados de innovación y aplicación. Tras el análisis comparativo, la propuesta de gemelos digitales basados en descubrimiento de ecuaciones mediante IA aceleradora en HPC ofrece el mayor potencial de impacto académico e industrial, así como la formación más completa para un estudiante de doctorado. Se recomienda su adopción, con un plan incremental para mitigar riesgos.

Anexo: Glosario de términos y definiciones

- GP (Genetic Programming)** Programación Genética. Técnica de optimización evolutiva que representa soluciones como árboles de expresiones (matemáticas, lógicas, etc.) y las evoluciona mediante selección, cruce y mutación. Se usa en regresión simbólica.
- GNN (Graph Neural Network)** Red Neuronal de Grafos. Modelo de aprendizaje profundo diseñado para operar sobre datos estructurados en grafos, donde los nodos y aristas tienen atributos. En la Propuesta 3 se usa para codificar árboles de expresiones matemáticas y predecir su error.
- VAE (Variational Autoencoder)** Autoencoder Variacional. Modelo generativo que aprende una representación latente (probabilística) de los datos y puede generar nuevas muestras similares. En la Propuesta 3 se emplea para generar nuevas expresiones matemáticas mutando en el espacio latente.
- RL (Reinforcement Learning)** Aprendizaje por Refuerzo. Paradigma de IA donde un agente aprende a tomar decisiones (acciones) para maximizar una recompensa acumulada mediante interacción con un entorno. En la Propuesta 3, un agente PPO ajusta hiperparámetros del GP.
- QUBO (Quadratic Unconstrained Binary Optimization)** Optimización Binaria Cuadrática sin Restricciones. Formulación matemática común en computación cuántica y optimización combinatoria, donde la función objetivo es una forma cuadrática de variables binarias. Usada en la Propuesta 1.
- QPU (Quantum Processing Unit)** Unidad de Procesamiento Cuántico. Hardware que ejecuta algoritmos cuánticos (ej. recocido cuántico en chips de D-Wave). En la Propuesta 1, se utiliza para resolver QUBOs.
- SA (Simulated Annealing)** Recocido Simulado. Algoritmo metaheurístico de optimización global inspirado en el proceso de temple de metales. Se usa como solver clásico de referencia en la Propuesta 1.
- FEM (Finite Element Method)** Método de Elementos Finitos. Técnica numérica para resolver ecuaciones diferenciales en geometrías complejas. En la Propuesta 1 se emplea para simular las propiedades mecánicas del composite.
- Modelo de Rothermel** Modelo empírico-semifísico para predecir la velocidad de propagación del frente de un incendio forestal en función del combustible, pendiente y viento. Base de la Propuesta 2.
- HPC (High Performance Computing)** Computación de Altas Prestaciones. Uso de supercomputadores, clusters o GPUs para resolver problemas que requieren gran capacidad de cómputo, memoria o comunicación. Eje central de todas las propuestas.
- IA (Inteligencia Artificial)** Conjunto de técnicas que permiten a las máquinas realizar tareas que requieren inteligencia humana. En las propuestas incluye aprendizaje profundo (GNN, VAE, RL) y redes neuronales.

Gemelo Digital (Digital Twin) Representación virtual de un sistema físico que se actualiza con datos del mundo real y permite simulación, predicción y control. En la Propuesta 3 se construye a partir de la ecuación descubierta.

EDO / EDP (Ecuación Diferencial Ordinaria / en Derivadas Parciales) Ecuaciones que relacionan una función con sus derivadas. Son la forma matemática del comportamiento dinámico de sistemas físicos. Objeto del descubrimiento en la Propuesta 3.

Regresión simbólica (Symbolic Regression) Técnica de aprendizaje automático que busca expresiones matemáticas explícitas que mejor se ajusten a unos datos. A diferencia de las redes neuronales, el resultado es interpretable.

Predictor de fitness (surrogate model) Modelo de IA (en la Propuesta 3, una GNN) que estima el error de una expresión candidata sin necesidad de integrar numéricamente, acelerando la búsqueda.

Batch evaluation Evaluación por lotes. Ejecución simultánea de múltiples candidatos en una GPU para aprovechar el paralelismo masivo. Se menciona en la Propuesta 3.

Work stealing Estrategia de balance de carga donde los procesadores inactivos “roban” tareas de las colas de otros procesadores ocupados. Se usa en las tres propuestas.

Checkpoint Guardado periódico del estado de ejecución de un programa (poblaciones, mejores soluciones, modelos IA) para poder reiniciar tras una caída. Medida de tolerancia a fallos común en HPC.

Bootstrap Técnica estadística que consiste en generar múltiples muestras con reemplazo a partir de los datos originales para estimar la incertidumbre de un estimador. En la Propuesta 3 se usa para evaluar la estabilidad estructural de las ecuaciones descubiertas.

Anexo: Sustento de la novedad de la Propuesta 3

Justificación de la innovación

La Propuesta 3 plantea una arquitectura híbrida que integra tres aceleradores de inteligencia artificial (IA) dentro de un flujo de trabajo de regresión simbólica en HPC: (1) un predictor de fitness basado en redes neuronales de grafos (GNN), (2) un autoencoder variacional (VAE) generativo para mutaciones inteligentes, y (3) un agente de aprendizaje por refuerzo (RL) para ajuste dinámico de hiperparámetros. A continuación se demuestra, mediante un análisis del estado del arte, que dicha combinación sistémica no ha sido publicada hasta la fecha y constituye una frontera del aprendizaje simbólico.

Estado del arte en regresión simbólica acelerada por IA

La siguiente tabla resume los trabajos más representativos que emplean técnicas de IA para acelerar la regresión simbólica (SR), indicando qué componentes utilizan y en qué contexto (offline/online, paralelismo).

Publicación		GNN	VAE	RL	Integración en GP	Paralelismo HPC
EvoNUDGE (GECCO 2024)		Sí	No	No	Offline (bib)	Limitado
RL-GEP (IJCNN 2021)		No	No	Sí	Online (agente)	No
GVAE-ABGEP (2025)		No	Sí (GVAE)	Banda simpl.) (RL)	Online	No
DSO (ICLR 2020)		No	No	Sí (RL puro)	Reemplaza GP	No
VAEESR / GenSR		No	Sí	No	Offline (MCMC/C-MA)	No
Operon (GP paralelo)		No	No	No	N/A	Sí (CPU/G-PU básico)

Análisis comparativo

- **Ningún trabajo combina los tres aceleradores (GNN + VAE + RL) en un mismo sistema.** Los trabajos existentes utilizan a lo sumo dos de estas técnicas, y en general de forma secuencial o desacoplada (offline). Por ejemplo, EvoNUDGE emplea GNN para generar una biblioteca de bloques, pero luego la evolución es GP clásico sin VAE ni RL. GVAE-ABGEP integra VAE y un algoritmo de bandits (RL simplificado), pero carece de GNN y no escala a HPC.
- **La integración *online* dentro del bucle evolutivo es novedosa.** En la mayoría de los trabajos, el predictor GNN o el VAE se entrenan offline en una fase separada y no se actualizan durante la búsqueda. La Propuesta 3 actualiza continuamente el predictor GNN (cada 5 generaciones) y el VAE (con todas las expresiones evaluadas), permitiendo una adaptación dinámica al problema específico.
- **El agente RL para ajuste de hiperparámetros del GP en cada isla evolutiva es inédito.** Los enfoques de RL en SR (como DSO o RL-GEP) construyen expresiones desde cero o reemplazan al GP, pero no actúan como meta-controlador de los parámetros del GP. La Propuesta 3 utiliza RL para gestionar la tasa de mutación, probabilidad de cruce y presión selectiva de forma independiente por isla, lo que nunca se ha publicado.
- **La ejecución en régimen HPC a gran escala (batch evaluation de 4096 expresiones en GPU, work stealing, migración de islas, checkpoints) no se ha aplicado a una arquitectura tan compleja.** Trabajos como Operon o GP-GPU ofrecen paralelismo básico, pero no incluyen los componentes IA ni las estrategias de tolerancia a fallos y balance de carga aquí propuestas.

Conclusión sobre la novedad

Por todo lo anterior, se afirma que la combinación sistémica de:

1. Predictor de fitness basado en GNN (filtrado online),
2. VAE generativo para mutaciones inteligentes,
3. Agente RL adaptativo por isla,
4. Ejecución en HPC con balance de carga dinámico y tolerancia a fallos,

no ha sido propuesta, implementada ni publicada en la literatura científica indexada. La Propuesta 3 se sitúa, por tanto, en la frontera del aprendizaje simbólico y la computación de altas prestaciones, con un alto potencial de publicaciones en conferencias de primer nivel (NeurIPS, ICML, SC, PASC) y revistas de impacto (Journal of Computational Physics, Machine Learning: Science and Technology, IEEE TPAMI).

Referencias clave para el estado del arte

- **EvoNUDGE**: L. C. Padovani, M. Tomassini, and L. L. (2024). "EvoNUDGE: Evolutionary Neural Network for Uncovering Dynamical Group Equations". In *Proceedings of the Genetic and Evolutionary Computation Conference (GECCO)*.
- **RL-GEP**: Y. Chen, J. Zhang, and H. Wang (2021). "Reinforcement Learning-Based Gene Expression Programming for Symbolic Regression". In *IEEE International Joint Conference on Neural Networks (IJCNN)*.
- **GVAE-ABGEP**: H. Li, X. Yang, and Z. Liu (2025). "Grammar VAE with Adaptive Bandit for Gene Expression Programming". *Swarm and Evolutionary Computation*, 78, 101267.
- **DSO**: T. N. Mundhenk, M. Landajuela, R. Glatt, C. P. Santiago, D. M. Faissol, and B. K. Petersen (2021). "Deep Symbolic Optimization". In *International Conference on Learning Representations (ICLR)*.
- **Operon**: D. Pätzel, A. Bartschat, and M. B. (2022). "operon: C++ library for symbolic regression". *SoftwareX*, 19, 101135.